

ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL

PROYECTO FINAL BUSINESS ANALYTICS

Implementación de un Data Warehouse

Elaborado por:

SERGIO ALEJANDRO VILLADA ARIAS
JULIÁN DAVID ARANZAZU VELÁSQUEZ

Docente:

LUZ ENITH GUERRERO MENDIETA

Facultad de Administración
Universidad Nacional de Colombia
Manizales, Colombia

Descripción del Problema

Contexto del Problema

En la actualidad, uno de los mayores desafíos a nivel global es comprender cómo las variaciones climáticas impactan directamente en la seguridad alimentaria y, en consecuencia, en la economía mundial. Eventos como sequías prolongadas o picos históricos de temperatura no solo afectan la cantidad de alimentos que se pueden cosechar en un país, sino que también generan escasez, lo que inevitablemente dispara los precios de los productos en el mercado internacional.

Para poder medir, cruzar y analizar este fenómeno desde una perspectiva de Business Analytics, hemos formulado un proyecto que busca encontrar la relación directa entre el clima, la producción agrícola y los precios del mercado. Para lograrlo, integramos la información de tres fuentes de datos públicas, heterogéneas y de alta fiabilidad:

- I. **Berkeley Earth:** Es una base de datos científica independiente que registra las temperaturas de la superficie terrestre. De aquí extrajimos los registros históricos de las anomalías térmicas (es decir, qué tanto más calor o frío hizo frente a lo normal) medidos de forma mensual y detallados por país. Esta es nuestra principal fuente para entender el comportamiento climático.
- II. **FAOSTAT:** Es la base de datos oficial de la Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO). Esta fuente nos proporciona las métricas exactas sobre el sector agropecuario a nivel mundial. De aquí tomamos los datos de volumen de producción, rendimiento de la tierra y áreas cosechadas para cultivos clave, organizados por año y por país.
- III. **Pinky Rose FIM (Fondo Monetario Internacional / Precios de Commodities):** Para conectar el clima y la agricultura con el impacto financiero, utilizamos esta fuente que rastrea el valor de los productos básicos (commodities) en los mercados globales. Nos aporta el precio de cotización mensual de diferentes rubros agrícolas. A diferencia de las otras dos fuentes, estos precios son un estándar global, lo que nos permite evaluar cómo un problema de cosecha en regiones clave afecta el bolsillo a nivel mundial.

Al integrar estas tres fuentes (que originalmente están en formatos y estructuras diferentes), el proyecto busca romper los silos de información. La idea no es solo mirar un reporte del clima o un reporte de finanzas por separado, sino construir un Data Warehouse que nos permita ver la "película completa" respaldar la toma de decisiones basada en la evidencia de los datos.

Objetivos analíticos

El objetivo general de este proyecto es diseñar e implementar una solución de Business Analytics, apoyada en un Data Warehouse, que permita comprender cómo las variaciones climáticas pueden afectar de manera directa la producción agrícola y, a partir de eso, influir también en los precios de los productos en el mercado global. La idea es integrar información de clima, agricultura y economía para analizar de forma conjunta estos tres componentes y así tener una visión más completa del problema, especialmente en temas relacionados con seguridad alimentaria y comportamiento de precios.

Para lograrlo, primero se busca extraer, limpiar e integrar los datos históricos provenientes de Berkeley Earth, FAOSTAT y Pinky Rose FIM, de manera que toda la información quede reunida en un solo repositorio y se elimine el manejo aislado de las fuentes. Después, se plantea construir un modelo de datos que permita relacionar las variables climáticas, agrícolas y económicas a partir de elementos comunes como el año, el mes y el país.

Con esta base, también se espera desarrollar tableros de control que faciliten la visualización del comportamiento de los datos y permitan identificar de forma más clara si los periodos de anomalías climáticas, como excesos de calor o frío, coinciden con disminuciones en la producción agrícola y aumentos en los precios de los alimentos. Finalmente, se propone incorporar herramientas de inteligencia artificial sobre los datos ya integrados, con el fin de apoyar la interpretación de los resultados, encontrar patrones que no sean tan evidentes a simple vista y darle un valor agregado al análisis realizado de forma tradicional.

Justificación de Valor

El valor fundamental de este proyecto radica en su capacidad para transformar datos históricos y dispersos en conocimiento accionable para la toma de decisiones estratégicas. Tradicionalmente, el análisis del impacto climático sobre la agricultura y la economía se hace de manera reactiva y fragmentada, pero al centralizar estas tres fuentes en un Data Warehouse creamos una "única fuente de verdad" que permite cruzar las variables de forma natural. El verdadero diferencial no es solo visualizar lo que ya pasó, sino preparar el terreno para que las herramientas de Inteligencia Artificial descubran patrones ocultos —como identificar cuánto tiempo tarda una anomalía térmica en encarecer un commodity específico—. Esto proporciona a investigadores, analistas o responsables de políticas públicas una base sólida y fundamentada en evidencia empírica para anticipar escenarios, formular estrategias de seguridad alimentaria o tomar decisiones de mercado, pasando de la intuición a una gestión verdaderamente basada en datos para tomar decisiones de mercado.

acuerdo con lo expuesto a manera de antesala del proyecto, a continuación, se desarrollarán las 6 fases del proyecto.

1. Parte 1. Procesos de Extracción, Transformación y Carga - ETL

Como parte de la descripción del proceso seguido, y como se ha mencionado anteriormente, fueron utilizadas tres fuentes de datos (Berkeley Earth, FAOSTAT, Pinky Rose FIM), de las cuales los datos se encontraban dispersos, con diferencias en su estructura, inconsistencias en su presentación, dificultades en la calidad, entre otros.

Por parte de **Berkeley Earth**, fueron obtenidos 164 archivos .txt con información climática correspondiente a 164 países. Al analizar la estructura interna de estos documentos, tomando como caso de estudio el archivo united-states.txt (Estados Unidos), identificamos las siguientes características y retos para su procesamiento

- **Metadatos integrados:** El archivo no inicia directamente con la tabla de datos, sino con un extenso encabezado de texto (comentado con el símbolo %). Este bloque explica la metodología de medición, indicando que las temperaturas están en grados Celsius y se reportan como anomalías en relación con el promedio histórico del periodo 1951-1980 (para el caso de Estados Unidos). En el proceso ETL, este encabezado debió ser filtrado para poder leer la matriz de datos.
- **Estructura del archivo:** Los datos no están separados por comas (como en un CSV tradicional), sino por espacios en blanco tabulados. La tabla contiene múltiples columnas, de las cuales identificamos como críticas para nuestro modelo: el Año (Year), el Mes (Month), la Anomalía Mensual (Monthly Anomaly) y la Incertidumbre Mensual (Monthly Uncertainty).
- **Problemas de Calidad (Datos Nulos):** El archivo presenta una gran cantidad de datos faltantes registrados bajo la etiqueta NaN (Not a Number), especialmente en los registros históricos más antiguos y en las columnas de promedios suavizados (a 1, 5 o 10 años). Por ello se hizo necesario establecer un rango de tiempo dónde se analizarán los datos, se tomó como punto de partida el año 1990 dónde empiezan los reportes del Pinky Rose y como año de finalización se tomó el año 2015 que es el último reporte de esta base de datos, de esta manera nos eliminamos el problema de los datos etiquetados con NaN.

% This file contains an extracted regional summary of land-surface % temperature results produced by the Berkeley Earth averaging % method for the region: % % United States % The Berkeley Earth method takes temperature observations from a large % collection of weather monitoring stations and produces an estimate of % the underlying global temperature field across all of the Earth's % land areas. Once this temperature field has been generated, it is % possible to estimate the temperature evolution of individual regions % simply by integrating the field over the region in question. This % file contains such a regional estimate.	% % Year, Month, % Monthly Anomaly, Unc., % Annual Anomaly, Unc., % Five-year Anomaly, Unc., % Ten-year Anomaly, Unc., % Twenty-year Anomaly, Unc.,	1768 9 -1.186 2.432 NaN NaN NaN NaN NaN NaN NaN NaN 1768 10 -1.818 2.829 NaN NaN NaN NaN NaN NaN NaN NaN 1768 11 -1.590 3.599 -0.663 2.124 NaN NaN NaN NaN NaN NaN 1768 12 -0.978 4.940 -0.429 2.084 NaN NaN NaN NaN NaN NaN 1769 1 -0.150 5.222 -0.378 2.092 NaN NaN NaN NaN NaN NaN 1769 2 -1.153 3.348 -0.300 2.357 NaN NaN NaN NaN NaN NaN 1769 3 -0.459 3.470 -0.244 2.249 NaN NaN NaN NaN NaN NaN 1769 4 0.537 3.991 -0.445 2.167 NaN NaN NaN NaN NaN NaN
--	--	--

% Estimated Jan 1951-Dec 1980 absolute temperature (C): 8.79 +/- 0.09											
% Estimated Jan 1951-Dec 1980 monthly absolute temperature (C):											
%	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov
%	-4.11	-1.77	2.18	8.09	13.93	18.77	21.49	20.50	16.29	9.76	2.79
% +/-	0.10	0.10	0.10	0.09	0.10	0.10	0.10	0.10	0.10	0.10	0.10
%											

Figura 1: Estructura original del archivo de Berkeley Earth.

Fuente: Elaboración propia con base en datos de Berkeley Earth.

Para convertir estos datos planos en una tabla estructurada, y poder analizar la información asertivamente, fueron desarrollados los siguientes scripts en Python que denominamos **01_country_name_mapping.py**, **02_download_berkeley_files.py** y **03_transform_berkeley_txt.py** (Scripts ETL), los cuales se encargaron de automatizar la extracción, estructurar el contenido y resolver problemas de calidad de datos:

- **01_country_name_mapping.py (Homologación y estandarización geográfica):** Este script fue desarrollado para resolver uno de los principales retos de integración entre fuentes heterogéneas: la diferencia en los nombres de países entre Berkeley Earth y FAOSTAT. Por ejemplo, mientras una fuente podía registrar *United States*, la otra utilizaba *United States of America*. Para evitar la pérdida de registros al cruzar las tablas, el script compara ambos catálogos de países, identifica coincidencias directas y analiza los casos restantes mediante técnicas de *Fuzzy Matching* con la librería *rapidfuzz*. Además, se incorporó una validación manual para corregir casos particulares y establecer equivalencias confiables entre ambas fuentes. Gracias a este proceso, fue posible definir un conjunto coherente de países para la descarga de información climática y fortalecer la consistencia de la dimensión geográfica del Data Warehouse.
- **02_download_berkeley_files.py (Automatización de la extracción):** Dado que descargar manualmente los archivos climáticos por país desde Berkeley Earth era un proceso ineficiente, este script fue desarrollado para automatizar la recolección de la información. El código parte de una lista de países previamente seleccionados y aplica un proceso de normalización de texto para construir el *slug* necesario en la URL de descarga, convirtiendo los nombres a minúsculas, eliminando tildes o caracteres especiales y reemplazando espacios por guiones. Posteriormente, el script construye la URL correspondiente para cada país, realiza la solicitud al servidor mediante una sesión HTTP y guarda los archivos *.txt* en una carpeta local. Además, verifica si cada archivo ya existe antes de descargarlo nuevamente, lo que permite optimizar el tiempo de ejecución y evitar descargas duplicadas.
- **03_transform_berkeley_txt.py (Transformación y estructuración en KNIME):** Este script opera dentro del flujo de KNIME y tiene como objetivo convertir los archivos climáticos *.txt* de Berkeley Earth en una tabla estructurada. Para ello, recibe desde KNIME la ruta del archivo, normaliza dicha ruta y lee el contenido del documento. Posteriormente, extrae el nombre del país desde el encabezado del archivo y obtiene la línea base mensual de temperatura, necesaria para calcular la temperatura absoluta. Luego recorre los registros numéricos, filtra el periodo de análisis entre 1990 y 2015, extrae el año, el mes, la anomalía térmica y la incertidumbre mensual, y calcula la temperatura absoluta sumando la anomalía a la línea base correspondiente. Finalmente, organiza estos resultados en un *DataFrame* con las columnas *Country*, *Year*, *Month*, *Anomaly_temp*, *Unc_temp* y *Abs_temperature_c*, el cual es devuelto como tabla de salida para continuar el proceso ETL en KNIME.

En cuanto a FAOSTAT, la información fue extraída descargando directamente la sábana de datos global desde su portal oficial, consolidada en el archivo *.csv* denominado *faos-*

tat_data.csv. Al explorar este conjunto de datos, encontramos un escenario estructural muy distinto al de los archivos de texto de Berkeley, el cual nos planteó los siguientes retos para el proceso ETL:

- **Elección de los distintos productos a analizar:** Dado que la fuente original contenía cerca de 300 ítems distintos entre cultivos y animales, fue necesario realizar un proceso manual de depuración y asociación. Esto se debió a que no todos los ítems podían vincularse directamente con al menos un commodity de Pinky Rose. Por ello, se extrajeron los distintos productos de la fuente y se estableció manualmente la correspondencia entre cada commodity y su respectivo cultivo o animal.
- **Estructura “Ancha” (Wide Format) y factor temporal:** El principal desafío analítico de este archivo es que el tiempo no está modelado como una variable en una sola columna, sino como múltiples columnas. Los registros de cada año aparecen extendidos horizontalmente hacia la derecha con el prefijo “Y” (ej. las columnas Y1961, Y1962... hasta los años más recientes). Para que esta información pudiera relacionarse con la dimensión temporal (dim_time) de nuestro Data Warehouse, era estrictamente necesario aplicar el nodo de Unpivoting en KNIME para transponer estas columnas y lograr un formato transaccional estándar, donde el “Año” quede en una columna y el valor numérico en otra.
- **Complejidad Semántica (Múltiples métricas integradas):** Observamos que el archivo contiene las columnas Element y Unit. Esto significa que los números reportados no representan una única métrica estándar. Dependiendo de la fila, el valor numérico puede significar “Producción” (medida en toneladas t), “Rendimiento”, o “Área Cosechada”. Esta particularidad nos obligó a ser muy cuidadosos en el modelado, justificando la necesidad de crear una dimensión adicional (dim_element) para darle el contexto correcto a la tabla de hechos y evitar sumar magnitudes incompatibles en los dashboards.
- **Granularidad de los datos:** Dado que los registros de FAOSTAT se presentan únicamente con periodicidad anual, fue necesario incorporar una columna Month con el valor predeterminado 0. De este modo, en la tabla de dimensiones temporal estos registros pueden identificarse como correspondientes a “All Year”.
- **Filtro por años:** Con el fin de garantizar la comparabilidad entre los distintos conjuntos de datos y evitar la inclusión de fechas no homogéneas, se optó por aplicar el mismo rango temporal empleado en Berkeley Earth, considerando únicamente los registros comprendidos entre 1990 y 2015.
- **Redundancia de códigos para identificación:** El dataset original está sobrecargado de identificadores para un mismo atributo. Por ejemplo, trae Area Code y Area Code (M49) los países, así como Item Code e Item Code (CPC) para los productos. En la fase de limpieza en KNIME, procedimos a filtrar todas estas columnas redundantes para aligerar la carga de procesamiento, conservando únicamente los nombres en texto limpio (Area e Item) y descartando las columnas Area Code (M49) e Item Code (CPC).

Finalmente, para integrar la variable económica al modelo (Pinky Rose FIM), utilizamos los registros de precios internacionales provenientes del archivo fim_data.xls. Al realizar la exploración de este conjunto de datos, identificamos particularidades estructurales que requirieron un tratamiento ETL específico en KNIME para poder acoplarlos a nuestra arquitectura:

- **Formato de series de tiempo combinadas:** A diferencia de las otras fuentes, cada fila de este archivo representa un periodo de tiempo, pero la fecha viene concatenada en un formato de texto alfanumérico en la primera columna (por ejemplo, 2026M2 para indicar febrero de 2026). Para poder enlazar estos datos con nuestra dimensión temporal (dim_time), fue necesario aplicar nodos de manipulación de texto (String Manipulation o Regex Split) para separar matemáticamente el “Año” y el “Mes” en dos columnas enteras independientes.
- **Estructura “Ancha” orientada a productos:** Los diferentes commodities agrícolas (trigo, maíz, café, etc.) no están en una sola columna, sino que cada producto es una columna independiente encabezada por su código técnico (ej. PMAIZMT, PCOFFOTM). Esto requirió ejecutar nuevamente un proceso de Unpivoting en KNIME. Al transponer los datos, logramos que todos los nombres bajaran a una columna llamada Commodity Name y todos los valores a una columna Commodity Value.
- **Filtro por años:** Con el fin de garantizar la comparabilidad entre los distintos conjuntos de datos y evitar la inclusión de fechas no homogéneas, se optó por aplicar el mismo rango temporal empleado en Berkeley Earth, considerando únicamente los registros comprendidos entre 1990 y 2015.
- **Filtro de commodities asociados a un item:** Dado que no todos los commodities están relacionados con un cultivo o un animal, fue necesario excluir aquellos vinculados a categorías no pertinentes para el análisis, como combustibles y metales. Una vez realizada la asociación manual en el dataset de FAOSTAT, se procedió a filtrar únicamente los commodities que resultaban utilizables.
- **Ausencia de Granularidad Geográfica:** Un hallazgo analítico clave durante la exploración fue constatar que esta fuente no contiene información por país. Los valores reportados son índices y precios de cotización en el mercado global. Esta característica de los datos fue la que determinó y justificó nuestra decisión arquitectónica en el esquema de constelación: la tabla de hechos de mercado (fact_commodity) no se conecta a la dimensión de geografía, asumiendo el precio como un factor macroeconómico que afecta a todos los países por igual.
- **Limpieza de Metadatos incrustados:** El archivo contenía filas iniciales que no eran datos numéricos, sino descripciones en texto de los códigos (ej. la fila Commodity.Description). Utilizamos nodos de filtrado de filas (Row Filter) para descartar esta “basura” de la cabecera antes de procesar los números y evitar errores de tipo de dato (Type Mismatch) al enviarlos a la base de datos relacional.

Así las cosas, a través de KNIME, se realizó el siguiente flujo:




Figura 2: Flujo en KNIME para la limpieza de datos Berkeley Earth.

Fuente: Elaboración propia con KNIME.




Figura 3: Flujo en KNIME para la limpieza de datos FAOSTAT.

Fuente: Elaboración propia con KNIME.




Figura 4: Flujo en KNIME para la limpieza de datos FMI.

Fuente: Elaboración propia con KNIME.

Una vez descargadas y revisadas las tres fuentes de datos, el proceso ETL fue organizado en KNIME mediante varios subflujos, cada uno orientado a una fuente específica: Berkeley Earth, FAOSTAT e IMF. Además, se incluyeron flujos auxiliares para extraer catálogos únicos y apoyar la homologación de productos o commodities entre las distintas bases. La

idea general del flujo fue llevar datos que inicialmente estaban dispersos, con formatos diferentes y estructuras poco compatibles, hacia archivos limpios y estandarizados que después pudieran integrarse de forma más clara en el Data Warehouse.

Producto de lo anterior, se generaron tres archivos .csv denominados “berkeley_clean”, “faostat_clean” y “imf_clean” (adjuntos), los cuales representan la materia prima estandarizada y lista para alimentar nuestro Data Warehouse. Su estructura final consolidada se describe a continuación:

- **berkeley_clean.csv:** Consolidó los registros climáticos en un formato netamente transaccional. El archivo ahora cuenta con columnas independientes y limpias para el país, el año, el mes, la anomalía térmica y la temperatura absoluta calculada en grados Celsius. Se eliminaron por completo las cabeceras de texto y los valores nulos (NaN) que presentaban los archivos originales.
- **faostat_clean.csv:** Este archivo refleja el éxito del proceso de despivotado (Unpivoting). Los más de 60 años que originalmente estaban distribuidos como columnas, se transformaron en una única variable de tiempo (Year), acompañada de su respectivo valor numérico (Value). Además, conserva intactas las columnas descriptivas del país (Area), el producto (Item) y el tipo de métrica (Element y Unit), garantizando que no se pierda el contexto del dato.
- **fmi_clean.csv:** Muestra la corrección exitosa de la estructura de mercado. Por un lado, la variable temporal original se separó matemáticamente en dos columnas enteras independientes (Year y Month). Por otro lado, los distintos códigos de los commodities agrícolas pasaron de ser encabezados de columna a estar listados bajo una única categoría (Commodity Name), emparejados con su precio global mensual correspondiente (Commodity Value).

Con la obtención de estos tres archivos limpios, homogéneos y con variables compartidas (como el Año y el País), se dio por concluida la parte 1 de limpieza y carga de los datos. A continuación, se aborda la segunda parte, modelamiento multidimensional del Data Warehouse.